

Exercice K-means :

Appliquer l'algorithme du K-means sur le dataset suivant en utilisant k=2 :

Point	X	Y
A	1	1
B	1	2
C	2	1
D	2	2
E	8	8
F	8	9
G	9	8
H	9	9

Solution :

1^{ère} itération :

K = 2 donc on a 2 classes

On choisit les points A et H comme étant les centroïdes de la première et la deuxième classe :

$$g_{C_1} = A = (1, 1)$$

$$g_{C_2} = H = (9, 9)$$

Au départ, les classes ne contiennent que les points A et B (les centres de gravité) :

$$C_1 = \{ A \}$$

$$C_2 = \{ B \}$$

On calcule les distances de chaque point avec les deux centres de gravité en utilisant la distance euclidienne :

$$D_{(B,g_{C_1})} = \sqrt[2]{(x_B - x_{g_{C_1}})^2 + (y_B - y_{g_{C_1}})^2} = \sqrt[2]{(1 - 1)^2 + (2 - 1)^2} = \sqrt[2]{0 + 1} = 1$$

$$D_{(B,g_{C_2})} = \sqrt[2]{(x_B - x_{g_{C_2}})^2 + (y_B - y_{g_{C_2}})^2} = \sqrt[2]{(1 - 9)^2 + (2 - 9)^2} = \sqrt[2]{64 + 49} = 10.63$$

⇒ B plus proche de g_{C_1} donc B appartient à C_1

$$D_{(C,g_{C_1})} = \sqrt[2]{(x_C - x_{g_{C_1}})^2 + (y_C - y_{g_{C_1}})^2} = \sqrt[2]{(2 - 1)^2 + (1 - 1)^2} = \sqrt[2]{1 + 0} = 1$$

$$D_{(C,g_{C_2})} = \sqrt[2]{(x_C - x_{g_{C_2}})^2 + (y_C - y_{g_{C_2}})^2} = \sqrt[2]{(2 - 9)^2 + (1 - 9)^2} = \sqrt[2]{49 + 64} = 10.63$$

⇒ C plus proche de g_{C_1} donc C appartient à C_1

$$D_{(D,g_{C_1})} = \sqrt[2]{(x_D - x_{g_{C_1}})^2 + (y_D - y_{g_{C_1}})^2} = \sqrt[2]{(2-1)^2 + (2-1)^2} = \sqrt[2]{1+1} = 1.41$$

$$D_{(D,g_{C_2})} = \sqrt[2]{(x_D - x_{g_{C_2}})^2 + (y_D - y_{g_{C_2}})^2} = \sqrt[2]{(2-9)^2 + (2-9)^2} = \sqrt[2]{49+49} = 9.89$$

\Rightarrow D plus proche de g_{C_1} donc D appartient à C_1

$$D_{(E,g_{C_1})} = \sqrt[2]{(x_E - x_{g_{C_1}})^2 + (y_E - y_{g_{C_1}})^2} = \sqrt[2]{(8-1)^2 + (8-1)^2} = \sqrt[2]{49+49} = 9.89$$

$$D_{(E,g_{C_2})} = \sqrt[2]{(x_E - x_{g_{C_2}})^2 + (y_E - y_{g_{C_2}})^2} = \sqrt[2]{(8-9)^2 + (8-9)^2} = \sqrt[2]{1+1} = 1.41$$

\Rightarrow E plus proche de g_{C_2} donc E appartient à C_2

$$D_{(F,g_{C_1})} = \sqrt[2]{(x_F - x_{g_{C_1}})^2 + (y_F - y_{g_{C_1}})^2} = \sqrt[2]{(8-1)^2 + (9-1)^2} = \sqrt[2]{49+64} = 10.63$$

$$D_{(F,g_{C_2})} = \sqrt[2]{(x_F - x_{g_{C_2}})^2 + (y_F - y_{g_{C_2}})^2} = \sqrt[2]{(8-9)^2 + (9-9)^2} = \sqrt[2]{1+0} = 1$$

\Rightarrow F plus proche de g_{C_2} donc F appartient à C_2

$$D_{(G,g_{C_1})} = \sqrt[2]{(x_G - x_{g_{C_1}})^2 + (y_G - y_{g_{C_1}})^2} = \sqrt[2]{(9-1)^2 + (8-1)^2} = \sqrt[2]{64+49} = 3.87$$

$$D_{(G,g_{C_2})} = \sqrt[2]{(x_G - x_{g_{C_2}})^2 + (y_G - y_{g_{C_2}})^2} = \sqrt[2]{(9-9)^2 + (8-9)^2} = \sqrt[2]{0+1} = 1$$

\Rightarrow G plus proche de g_{C_2} donc G appartient à C_2

$$C1 = \{A, B, C, D\}$$

$$C2 = \{E, F, G, H\}$$

On recalcule les centroïdes des deux classes

$$g_{C_1} = \frac{x_A + x_B + x_C + x_D}{4}, \frac{y_A + y_B + y_C + y_D}{4}$$

$$g_{C_1}=\frac{1+1+2+2}{4},\frac{1+2+1+2}{4}$$

$$\textbf{\textit{g}}_{C_1}=\frac{\textbf{3}}{2},\frac{\textbf{3}}{2}$$

$$g_{C_2}=\frac{x_H+x_E+x_G+x_F}{4},\frac{y_H+y_E+y_G+y_F}{4}$$

$$g_{C_2}=\frac{8+8+9+9}{4},\frac{8+9+8+9}{4}$$

$$\textbf{\textit{g}}_{C_2}=\frac{\textbf{17}}{2},\frac{\textbf{17}}{2}$$